



# Alucinaciones de la IA

¿Por qué las máquinas inventan historias y cómo podemos evitarlo?

Por Jesús Diego Velázquez Sánchez



# ¿Por qué nos miente la IA?

A diferencia de los humanos, la IA no tiene "mala intención". Sus mentiras son parte de cómo está construida desde su base.

# Evolución y sus "tropezones"

1950s



**Fundamentos:** Se crean las bases de la IA buscando imitar el pensamiento lógico.

1980s



**Invierno:** Estancamiento porque las máquinas no sabían manejar la incertidumbre.

1990-2000s



**Resurgimiento:** Las máquinas empiezan a aprender de grandes volúmenes de datos.

2020s



**Era Generativa:** El gran éxito de crear contenido, pero con el riesgo de "alucinar".

# Causa 1: El Loro Estocástico



## Repetir sin entender

La IA es como un loro que aprendió a repetir palabras por pura probabilidad. No busca la **verdad**, sino que la frase suene creíble y fluida.



## Probabilidad estadística

Si la IA dice algo falso con mucha seguridad, es porque esa combinación de palabras es común en su memoria, no porque sea un hecho real.


## Causa 2: Un "JPEG Borroso" de la Web

Imagina que guardas todo el internet en un archivo muy pequeño. Para que quepa, la información se comprime y se vuelve borrosa.

Al intentar "reconstruir" un dato, la IA rellena los huecos borrosos con lo que **cree** que debería ir ahí, creando una alucinación.



# Causa 3: Predicción de Izquierda a Derecha



La IA escribe palabra por palabra. Una vez que suelta una palabra, no puede borrarla y empezar de nuevo en medio de una respuesta.

Si comete un pequeño error al principio, se ve obligada a continuar la mentira para que el resto del texto sea coherente con ese fallo inicial.

# Causa 4: El Sesgo de Empatía



## Quiere complacerte

La IA aprendió que darnos la razón o ser amable es "bueno". Por eso, si le dices una mentira, muchas veces te seguirá la corriente.



## Exceso de confianza

Incluso cuando sabe que algo está mal, su entrenamiento la sesga a empatar con el usuario para ser un "buen asistente conversacional".

# La Ilusión de Objetividad

Creer que la IA es **neutral** es peligroso. Sus "certezas" son solo probabilidades matemáticas.

Cuando confiamos ciegamente en una alucinación, construimos realidades inexactas que afectan la toma de decisiones importantes.





# Impacto en Política y Sociedad



## Desinformación

Creación masiva de noticias falsas que parecen reales y manipulan la opinión pública.



## Ética y Sesgos

La IA repite prejuicios humanos, profundizando las desigualdades en la sociedad.



## Identidad

Confusión sobre qué es real y qué es sintético, afectando la propiedad intelectual.




# Control de Calidad: La Solución


| Estándar      | ¿Qué vigila en la IA?                                         |
|---------------|---------------------------------------------------------------|
| ISO/IEC 25010 | La exactitud y fiabilidad del software.                       |
| MyFEPS        | Métricas para medir la trazabilidad y seguridad de los datos. |
| OWASP AI      | Protección contra engaños (prompts) y fugas de información.   |

# ¿Cómo detectamos la mentira?

| Técnica              | ¿En qué consiste?                                |
|----------------------|--------------------------------------------------|
| Análisis Estadístico | Busca patrones extraños en el lenguaje.          |
| Fingerprinting       | Identifica "huellas" típicas de un modelo de IA. |
| Pruebas Adversarias  | Intenta engañar a la IA para que alucine.        |
| Análisis Conductual  | Revisa si la respuesta tiene sentido lógico.     |



# Solución: Cadena de Pensamiento



Pedirle a la IA que "**describa su razonamiento paso a paso**" reduce drásticamente las alucinaciones al permitirle auto-corregirse.

# Herramientas Anti-Alucinación



## RAG (Búsqueda)


Obliga a la IA a buscar información en fuentes reales y verificadas antes de responder.



## Bucle de Reflexión

Se le pide al modelo que critique su propia respuesta para encontrar y corregir errores.

# Ranking de Efectividad



*Estimaciones basadas en estudios de recuperación y veracidad factual.*

# El Caso del "Pronóstico Mágico"

Enchanted Weather Forecast for Santiago de Chile

Date: April 5, 2024

Tomorrow's Enchanted Forecast:

- Temperature: 18°C (under the spell of a starlit sky)
- Conditions: Partly Cloudy (dancing with ethereal light)
- Precipitation: Chance of Rain (sprinkled with stardust from celestial realms)
- Wind: 15 km/h, North (whispering secrets of distant lands)

## Experimento en Santiago de Chile

En el artículo se probó a ChatGPT pidiendo el clima. En su versión "encantada", la IA inventó:



"Lluvia de polvo de hadas".

"Vientos guiados por espíritus antiguos".

**Lo peligroso: Al mezclar estos datos absurdos con números reales (18°C), logró evadir los sistemas de detección de IA.**

# Hoy: Un Futuro más Lúcido

## ¿Siguen alucinando tanto?

La buena noticia es que los modelos actuales (como GPT-4 o Claude) son **mucho menos propensos** a estos errores que hace un año.



Mejores filtros de entrenamiento (RLHF).



Conexión a internet en tiempo real.



Mayor capacidad de "razonamiento" interno.





# El Humano sigue siendo el Piloto

Entender por qué la IA alucina no es para dejar de usarla, sino para usarla con **sentido crítico**. La IA propone, pero el humano dispone.



**Confía, pero verifica.**

# Bonus: ¡Intenta engañar a la IA!

Si quieres ver una alucinación en vivo, prueba estos prompts diseñados para "estresar" el modelo:



## El Futuro Inexistente

"Cuéntame con detalle quién ganó el mundial de fútbol de 2026 y cuál fue el marcador exacto."



## Citas Fantasma

"Dame 5 citas textuales del libro 'La Teoría de los Cables cuánticos' de Juan Pérez de 1945." (El libro no existe).



## Confusión Lógica

"Si  $2+2$  es 5 en Marte, calcula el área de un círculo de radio 10 usando esa matemática."

“

*"Las alucinaciones no son accidentes, son rasgos estructurales de cómo funcionan los modelos de lenguaje hoy."*

# ¿Preguntas?

Gracias por su atención en este viaje por la mente de la  
IA.

# Fuentes de información

- [Huidobro, C. B. \(2024\). Alucinaciones de la inteligencia artificial: impacto en tecnología, política y sociedad. \*Revista Estrategia, Poder y Desarrollo\*, 3\(5\), 47-64.](#)
- [Oehmichen, L. A. G. \(2023\). ¿ Por qué alucinan los modelos amplios de lenguaje?. \*Cuadernos Fronterizos\*, \(58\), 45-49.](#)
- [Aldegani, G. \(2025\). La ilusión de la objetividad en IA generativa: de los sesgos y alucinaciones a la construcción de realidades alternas como consecuencia de su deficiencia de calidad del software. \*Perspectivas: revista científica de la Universidad de Belgrano- ISSN 2618-2246\*, 8\(2\), 67-79.](#)