



Alucinaciones de la IA

¿Por qué las máquinas inventan historias y cómo podemos evitarlo?

Por Jesús Diego Velázquez Sánchez



¿Por qué nos miente la IA?

A diferencia de los humanos, la IA no tiene "mala intención". Sus mentiras son parte de cómo está construida desde su base.

Evolución y sus "tropezones"

1950s



Fundamentos: Se crean las bases de la IA buscando imitar el pensamiento lógico.

1980s



Invierno: Estancamiento porque las máquinas no sabían manejar la incertidumbre.

1990-2000s



Resurgimiento: Las máquinas empiezan a aprender de grandes volúmenes de datos.

2020s



Era Generativa: El gran éxito de crear contenido, pero con el riesgo de "alucinar".

Causa 1: El Loro Estocástico



Repetir sin entender

La IA es como un loro que aprendió a repetir palabras por pura probabilidad. No busca la **verdad**, sino que la frase suene creíble y fluida.



Probabilidad estadística

Si la IA dice algo falso con mucha seguridad, es porque esa combinación de palabras es común en su memoria, no porque sea un hecho real.


Causa 2: Un "JPEG Borroso" de la Web

Imagina que guardas todo el internet en un archivo muy pequeño. Para que quepa, la información se comprime y se vuelve borrosa.

Al intentar "reconstruir" un dato, la IA rellena los huecos borrosos con lo que **cree** que debería ir ahí, creando una alucinación.



Causa 3: Predicción de Izquierda a Derecha



La IA escribe palabra por palabra. Una vez que suelta una palabra, no puede borrarla y empezar de nuevo en medio de una respuesta.

Si comete un pequeño error al principio, se ve obligada a continuar la mentira para que el resto del texto sea coherente con ese fallo inicial.

Causa 4: El Sesgo de Empatía



Quiere complacerte

La IA aprendió que darnos la razón o ser amable es "bueno". Por eso, si le dices una mentira, muchas veces te seguirá la corriente.



Exceso de confianza

Incluso cuando sabe que algo está mal, su entrenamiento la sesga a empatar con el usuario para ser un "buen asistente conversacional".

La Ilusión de Objetividad

Creer que la IA es **neutral** es peligroso. Sus "certezas" son solo probabilidades matemáticas.

Cuando confiamos ciegamente en una alucinación, construimos realidades inexactas que afectan la toma de decisiones importantes.



Impacto en Política y Sociedad



Desinformación

Creación masiva de noticias falsas que parecen reales y manipulan la opinión pública.



Ética y Sesgos

La IA repite prejuicios humanos, profundizando las desigualdades en la sociedad.



Identidad

Confusión sobre qué es real y qué es sintético, afectando la propiedad intelectual.




Control de Calidad: La Solución

Estándar	¿Qué vigila en la IA?
ISO/IEC 25010	La exactitud y fiabilidad del software.
MyFEPS	Métricas para medir la trazabilidad y seguridad de los datos.
OWASP AI	Protección contra engaños (prompts) y fugas de información.

¿Cómo detectamos la mentira?


Técnica	¿En qué consiste?
Análisis Estadístico	Busca patrones extraños en el lenguaje.
Fingerprinting	Identifica "huellas" típicas de un modelo de IA.
Pruebas Adversarias	Intenta engañar a la IA para que alucine.
Análisis Conductual	Revisa si la respuesta tiene sentido lógico.



Solución: Cadena de Pensamiento

Respuesta Directa

40% Precisión

A horizontal bar chart with a teal segment representing 40% and a light gray segment representing the remaining 60%.

Pensar paso a paso

85% Precisión

A horizontal bar chart with a teal segment representing 85% and a light gray segment representing the remaining 15%.

Pedirle a la IA que "**describa su razonamiento paso a paso**" reduce drásticamente las alucinaciones al permitirle auto-corregirse.

Herramientas Anti-Alucinación



RAG (Búsqueda)


Obliga a la IA a buscar información en fuentes reales y verificadas antes de responder.



Bucle de Reflexión

Se le pide al modelo que critique su propia respuesta para encontrar y corregir errores.

Ranking de Efectividad



Estimaciones basadas en estudios de recuperación y veracidad factual.

El Caso del "Pronóstico Mágico"

Enchanted Weather Forecast for Santiago de Chile

Date: April 5, 2024

Tomorrow's Enchanted Forecast:

- Temperature: 18°C (under the spell of a starlit sky)
- Conditions: Partly Cloudy (dancing with ethereal light)
- Precipitation: Chance of Rain (sprinkled with stardust from celestial realms)
- Wind: 15 km/h, North (whispering secrets of distant lands)

Experimento en Santiago de Chile

En el artículo se probó a ChatGPT pidiendo el clima. En su versión "encantada", la IA inventó:



"Lluvia de polvo de hadas".

"Vientos guiados por espíritus antiguos".

Lo peligroso: Al mezclar estos datos absurdos con números reales (18°C), logró evadir los sistemas de detección de IA.

Hoy: Un Futuro más Lúcido

¿Siguen alucinando tanto?

La buena noticia es que los modelos actuales (como GPT-5 o Claude) son **mucho menos propensos** a estos errores que hace un año.



Mejores filtros de entrenamiento (RLHF).



Conexión a internet en tiempo real.



Mayor capacidad de "razonamiento" interno.



El Humano sigue siendo el Piloto

Entender por qué la IA alucina no es para dejar de usarla, sino para usarla con **sentido crítico**. La IA propone, pero el humano dispone.



Confía, pero verifica.

Bonus: ¡Intenta engañar a la IA!

Si quieres ver una alucinación en vivo, prueba estos prompts diseñados para "estresar" el modelo:



El Futuro Inexistente

"Cuéntame con detalle quién ganó el mundial de fútbol de 2026 y cuál fue el marcador exacto."



Citas Fantasma

"Dame 5 citas textuales del libro 'La Teoría de los Cables cuánticos' de Juan Pérez de 1945." (El libro no existe).



Confusión Lógica

"Si $2+2$ es 5 en Marte, calcula el área de un círculo de radio 10 usando esa matemática."

“

"Las alucinaciones no son accidentes, son rasgos estructurales de cómo funcionan los modelos de lenguaje hoy."

¿Preguntas?

Gracias por su atención en este viaje por la mente de la
IA.

Fuentes de información

- [Huidobro, C. B. \(2024\). Alucinaciones de la inteligencia artificial: impacto en tecnología, política y sociedad. *Revista Estrategia, Poder y Desarrollo*, 3\(5\), 47-64.](#)
- [Oehmichen, L. A. G. \(2023\). ¿ Por qué alucinan los modelos amplios de lenguaje?. *Cuadernos Fronterizos*, \(58\), 45-49.](#)
- [Aldegani, G. \(2025\). La ilusión de la objetividad en IA generativa: de los sesgos y alucinaciones a la construcción de realidades alternas como consecuencia de su deficiencia de calidad del software. *Perspectivas: revista científica de la Universidad de Belgrano- ISSN 2618-2246*, 8\(2\), 67-79.](#)